

TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Visualização de Dados
Fase 1

Nome do estudante: Denise Almeida de Souza

DESCRIÇÃO DO CONJUNTO DE DADOS ESCOLHIDO

Deve ser apresentado o dicionário de dados, ou seja, origem (link), uma descrição de cada campo do arquivo e total de registros. **IMPORTANTE:** o arquivo de dados deve ter no **mínimo 10 campos**, **mínimo 1000 registros** e **estar no formato csv**. Não podem ser usados os arquivos de dados já trabalhados nas aulas.

O tema a ser explorado no desenvolvimento deste trabalho é um conjunto de dados que aborda uma projeção de impacto da AI no mercado de trabalho em 2030. Os dados trazem informações essencialmente categóricas sobre a indústria, geolocalização, informações de empregados e projeções sendo elas de índice de risco de substituição da IA e de demandas futuras.

Podemos explorar dimensões do tema para prever novas carreiras, funções que serão as mais afetadas, o impacto no setor e como essas tendências se comportam geograficamente, propondo uma reflexão para traçar estratégias de carreira e desenvolvimento de profissionais para o futuro.

Em essência a própria exploração pode enfatizar a ideia de mudanças de paradigmas para a sociedade, assim como o entendimento e significado do impacto ecológico, trazendo outras perspectivas para o assunto.

Origem (link):

<https://www.kaggle.com/datasets/muhammadwaqas023/ai-impact-in-future-on-jobs-market-in-2030>

Descrição de cada campo (o conjunto de dados deve ter no mínimo 10 campos):

Dados Categóricos

- Employee_ID (Identificador): Código único de registro de cada funcionário (Ex: AIJ-100000).
- Job_Title (Nominal): O cargo ou função ocupada pelo profissional (Ex: Data Engineer).
- Industry (Nominal): Setor econômico de atuação da empresa (Ex: Healthcare, Retail).
- Country (Nominal): País onde o profissional reside ou atua (Ex: Japan, UK, Canada).
- Education_Level (Ordinal): Grau de escolaridade formal (Ex: High School, Bachelor, PhD).
- Remote_Work_Possibility (Binário): Indica se o trabalho possui viabilidade remota (Yes ou No).
- Required_Skills (Texto / Lista): Relação de habilidades técnicas e interpessoais exigidas para o cargo.
- Automation_Level (Ordinal): Nível atual de automação das tarefas diárias (Low, Medium, High).
- Company_Size (Nominal): Porte da empresa empregadora (Ex: Startup, Enterprise).
- AI_Tool_Usage (Ordinal): Frequência de uso de ferramentas de IA no dia a dia (Low, Moderate, High).
- Upskilling_Needed (Binário): Indica se o profissional precisa passar por requalificação (Yes ou No).

- Hiring_Trend_2026 (Ordinal): Tendência de contratação para a área até 2026 (Growing, Stable, Declining).

Dados Numéricos

- Years_Experience (Discreto): Tempo total de experiência profissional acumulada (em anos).
- AI_Replacement_Risk (Contínuo): Probabilidade matemática do cargo ser substituído por IA (Escala de 0 a 1).
- Future_Demand_Score (Contínuo): Pontuação indicativa da força de demanda futura pelo cargo (Escala de 0 a 1).
- Average_Salary_USD (Contínuo): Remuneração média anual convertida em dólares americanos (USD).
- Job_Growth_2030 (Discreto): Estimativa de crescimento ou declínio percentual de vagas até o ano de 2030.
- Work_Hours_Per_Week (Discreto): Carga horária de trabalho regular dedicada por semana (em horas).
- Performance_Score (Contínuo): Pontuação de avaliação de desempenho do funcionário.
- Job_Satisfaction (Contínuo): Índice reportado de satisfação geral com o emprego e as funções exercidas.

Total de registros (mínimo 1000):

Total do data-set: 3000 linhas

DESCRIÇÃO DA ANÁLISE DOS DADOS

Devem ser apresentadas **informações e gráficos sobre o conteúdo e a qualidade dos dados**, isto é, *insights* obtidos com a análise exploratória visual (incluindo gráficos), e uma descrição sobre o enriquecimento dos dados (se realizado). **IMPORTANTE:** para esta apresentação, use uma das ferramentas trabalhadas em aula, como o **ydata-profiling** (acesse as aulas 1 e 2 para saber mais sobre as ferramentas).


Para apresentar a solução da análise exploratória de dados do dataset, foi escolhida o framework y-data-profiling a ser executado via código Python em ambiente local.

Utilizando o Profiling Report podemos observar que este dataset já se encontra pré-processado, um dos indicadores é o percentual de 0% de valores faltantes, assim como linhas duplicadas.

Profiling Report		Overview Variables Interactions Correlations Missing values	
Overview Alerts 3 Reproduction			
Dataset statistics		Variable types	
Number of variables	20	Text	2
Number of observations	3000	Categorical	9
Missing cells	0	Numeric	8
Missing cells (%)	0.0%	Boolean	1
Duplicate rows	0		
Duplicate rows (%)	0.0%		
Total size in memory	468.9 KiB		
Average record size in memory	160.0 B		

Um outro aspecto da afirmação dos dados com valores faltantes:

Missing values



Amostra dos dados:

Sample

First rows

Last rows

	Employee_ID	Job_Title	Industry	Country	Education_Level	Years_Experience	AI_Risk_Score
0	AIJ-100000	Data Engineer	Healthcare	Japan	PhD	1	0.25
1	AIJ-100001	Healthcare Analyst	Retail	UK	Bachelor	24	0.73
2	AIJ-100002	HR Specialist	Education	Canada	High School	21	0.80
3	AIJ-100003	Cybersecurity Analyst	Government	UK	Bachelor	5	0.29
4	AIJ-100004	Healthcare Analyst	Education	UAE	PhD	20	0.11
5	AIJ-100005	Machine Learning Engineer	Energy	Japan	High School	12	0.73
6	AIJ-100006	UX Designer	Media	UK	High School	20	0.46
7	AIJ-100007	Digital Marketer	Technology	Germany	High School	2	0.15

DESCRIÇÃO DAS QUESTÕES DE NEGÓCIO

Devem ser definidas, **no mínimo, 3 questões de negócio**, ou seja, o que se quer descobrir com o *dashboard* que será desenvolvido.

Questão de negócio 1:

Quais indústrias correm o maior risco médio de substituição por IA até 2030?

Identificar as áreas da indústria com maior probabilidade de substituição por IA para ações de qualificação prévia de novos modelos e paradigma de trabalho.

Questão de negócio 2:

Quais são as habilidades necessárias em relação aos trabalhos que terá crescimento até 2030?

A proposta é identificar as habilidades necessárias para o futuro, disponibilizando aos profissionais tendências para capacitação prévia.

Questão de negócio 3:

Quais são os países que possuem mais profissionais com habilidades necessárias?

Podemos realizar uma análise geográfica da concentração de profissionais que possuem as habilidades de maior necessidade futura para incentivar a aplicação de políticas públicas e privadas de educação para contribuir com o desenvolvimento do país.

Questão de negócio 4 (OPCIONAL):

Quais profissões utilizam mais ferramentas de AI no dia a dia?

Queremos observar quais são os profissionais que já utilizam de forma constante AI no seu dia a dia e entender se existem alguma correlação com possível substituição de AI ou trabalhos que haverá crescimento até 2030.

LISTA E JUSTIFICATIVA DAS REPRESENTAÇÕES VISUAIS A SEREM IMPLEMENTADAS

Devem ser listadas todas as representações visuais que farão parte do *dashboard* que será implementado na Fase 2. Além disso, para cada representação visual deve ser colocada uma justificativa para a sua escolha e devem ser listados os campos dos dados que serão utilizados para sua futura implementação. **IMPORTANTE:** o *dashboard* a ser implementado na Fase 2 deve ter de 5 a 6 diferentes técnicas de visualização interativa para ajudar a responder as questões de negócio.

Representação visual 1:

Gráfico de Barras

Questão de Negócio: Questão 1

Justificativa: O gráfico de barras é a técnica ideal para comparar valores numéricos entre múltiplas categorias.

Campos: Industry e AI_Replacement_Risk

Representação visual 2:

Nuvem de Palavras Dinâmica

Questão de Negócio: Questão 2

Justificativa: As habilidades estão armazenadas em uma lista, desta forma, a visualização tem maior impacto ao utilizar essa representação relacionando as palavras e a frequência.

Campos: Required_Skills e Job_Growth_2030

Representação visual 3:

Gráfico de Árvore (Treemap)

Questão de Negócio: Questão 2

Justificativa: O Treemap complementa a Nuvem de Palavras ao organizar o volume de dados em estruturas retangulares hierárquicas e proporcionais.

Campos: Required_Skills e Job_Growth_2030

Representação visual 4:

Mapa de Calor Geográfico

Questão de Negócio: Questão 3

Justificativa: O mapa coroplético preencherá as fronteiras dos países com intensidades de cor baseadas no volume de profissionais qualificados para o futuro.

Campos: Country e Employee_ID

Representação visual 5:

Gráfico de Caixa (Boxplot)

Questão de Negócio: Questão 3

Justificativa: Avaliar a distribuição e a dispersão das qualificações e indicadores de futuro dos profissionais agrupados por país.

Representação visual 6:

Gráfico de Dispersão com Bolhas

Questão de Negócio: Questão 4

Justificativa: O gráfico cruzará a frequência de uso da IA com o risco de substituição e o crescimento da vaga ao mesmo tempo.

Campos: AI_Tool_Usage, AI_Replacement_Risk e Job_Title